



Instituto de Biología  
UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO



# Taller práctico:

## Clasificando secuencias biológicas con Deep Learning



Alida Zárate




Cuernavaca, Morelos a 12 de Septiembre

2025

# Clasificar proteínas virales

## Clase



# ¿Cómo obtenemos las secuencias de proteínas virales?

- Plataforma NCBI Virus
- <https://www.ncbi.nlm.nih.gov/labs/virus/vssi/#>
- Descargamos

| Clase              | # secuencias descargadas<br>>300aa |
|--------------------|------------------------------------|
| Sars-Cov-2         | 2,278 Estratificadas por país      |
| Orthoherpesviridae | 2,401                              |
| Bacteriófagos      | 3,061                              |



# Archivos Fasta

| Accesion                                           | Familia       | Género          | Especie                    | Linaje  | Host         | País  |
|----------------------------------------------------|---------------|-----------------|----------------------------|---------|--------------|-------|
| >XDI95720.1                                        | Coronaviridae | Betacoronavirus | Betacoronavirus pandemicum | BF.7.14 | Homo sapiens | China |
| ORF1a polyprotein 4402                             |               |                 |                            |         |              |       |
| MESLVPGFNEKTHVQLSLPVLQVRDVLVRGFGDSVEEVLSEARQHLKDGT |               |                 |                            |         |              |       |
| CGLVEVEKGVLPQLEQPYVFIKRSDARTAPHGHVMV               |               |                 |                            |         |              |       |
| ELVAELEGIQY                                        |               |                 |                            |         |              |       |

Secuencia

# Introducción

## ¿Qué Inteligencia Artificial? ¿Deep Learning?


### Inteligencia Artificial

Hacer que las máquinas aprendan a realizar tareas que normalmente requieren inteligencia humana, como reconocer imágenes, entender lenguaje o tomar decisiones.

### Deep Learning

Es una técnica dentro de la IA que utiliza Redes Neuronales Profunda (capas), para aprender representaciones y patrones complejos **directamente a partir de los datos.**

### Aplicando Deep Learning para clasificar entre Perros y Gatos Redes Convolucionales CNN's




- Aprende a partir de miles de imágenes etiquetadas.
- Generalización
- Se puede aplicar a cualquier problema como clasificación de enfermedades, sonidos, texto, proteínas virales etc.

# Antecedentes Deep learning


## CNN:

Utiliza capas de convolución para extraer patrones locales (mapas de características)

LeCun, Y. (2015)




Función de activación **ReLU**:  
Introduce la **no linealidad** para capturar relaciones complejas




## ResNets:

- Emplean capas convolucionales
- Bloques residuales
- Evita el desvanecimiento del gradiente gracias a las conexiones directas entre capas
- He, K. (2015)




## Max Pooling:

- Reduce la **dimensionalidad** al seleccionar el valor máximo en cada ventana
- Disminuye la complejidad computacional




## Softmax:

Convertir las salidas en probabilidades normalizadas para cada clase



# Épocas – Iteraciones – Batch\_Size



# ¿Qué es una proteínas viral?

Una **macromolécula biológica** formada por largas cadenas de **aminoácidos** unidos por enlaces peptídicos.

Se Se organizan en cuatro niveles estructurales:

- **Estructura primaria:** Secuencia lineal de aminoácidos.
- **Estructura secundaria:** Plegamientos locales como hélices  $\alpha$  y láminas  $\beta$ .
- **Estructura terciaria:** Plegamiento tridimensional de la proteína completa.
- **Estructura cuaternaria:** Asociación de múltiples cadenas polipeptídicas (si aplica).


Diversidad funcional:

**Enzimas** (catalizadores de reacciones).

**Receptores celulares.**

**Formar estructuras celulares** (ej. colágeno, queratina).

**Transportar moléculas** (ej. hemoglobina para oxígeno).




# Proteína viral

Una **proteína viral** es una proteína producida por un virus, utilizando los recursos de la célula huésped para su síntesis. Estas proteínas son fundamentales para el **ciclo de vida del virus**, ya que participan en procesos como la **infección, replicación y ensamblaje** del virión (la partícula viral completa)

Bacteriófagos: Media 150 -500 aa

Eucariontes: Media 300 -500 aa

Ej. La proteína Spike (S) consta de **1273 aa**




ATGTACGCCGTAGCT ...

Ala



Metionina, Tirosina, Alanina, Valina, Alanina  
AMINOACIDOS  
Estructura



SARS-CoV-2. Lubin *et al.*,  
2020

# Codificación de proteínas

Segunda letra

| Primera letra | Segunda letra                            |                                      |                                            |                                           | Tercera letra |
|---------------|------------------------------------------|--------------------------------------|--------------------------------------------|-------------------------------------------|---------------|
|               | U                                        | C                                    | A                                          | G                                         |               |
|               | UUU } Phe<br>UUC }<br>UUA } Leu<br>UUG } | UCU } Ser<br>UCC }<br>UCA }<br>UCG } | UAU } Tyr<br>UAC }<br>UAA Alto<br>UAG Alto | UGU } Cys<br>UGC }<br>UGA Alto<br>UGG Trp |               |
|               | CUU }<br>CUC } Leu<br>CUA }<br>CUG }     | CCU }<br>CCC } Pro<br>CCA }<br>CCG } | CAU } His<br>CAC }<br>CAA } Gln<br>CAG }   | CGU }<br>CGC } Arg<br>CGA }<br>CGG }      |               |
|               | AUU }<br>AUC } Ile<br>AUA }<br>AUG Met   | ACU }<br>ACC } Thr<br>ACA }<br>ACG } | AAU } Asn<br>AAC }<br>AAA } Lys<br>AAG }   | AGU } Ser<br>AGC }<br>AGA } Arg<br>AGG }  |               |
|               | GUU }<br>GUC } Val<br>GUA }<br>GUG }     | GCU }<br>GCC } Ala<br>GCA }<br>GCG } | GAU } Asp<br>GAC }<br>GAA } Glu<br>GAG }   | GGU }<br>GGC } Gly<br>GGA }<br>GGG }      |               |

| Aminoácidos |        |              |        |        |                 |
|-------------|--------|--------------|--------|--------|-----------------|
| Código      | Código | Nombre       | Código | Código | Nombre          |
| 18 V        | Val    | Valina       | 1 A    | Ala    | Alanina         |
| 10 L        | Leu    | Leucina      | 13 P   | Pro    | Prolina         |
| 17 T        | Thr    | Treonina     | 6 G    | Gly    | Glicina         |
| 9 K         | Lys    | Lisina       | 16 S   | Ser    | Serina          |
| 19 W        | Trp    | Triptófano   | 2 C    | Cys    | Cisteína        |
| 7 H         | His    | Histidina    | 12 N   | Asn    | Asparagina      |
| 5 F         | Phe    | Fenilalanina | 14 Q   | Gln    | Glutamina       |
| 8 I         | Ile    | Isoleucina   | 20 Y   | Tyr    | Tirosina        |
| 15 R        | Arg    | Arginina     | 3 D    | Asp    | Ácido aspártico |
| 11 M        | Met    | Metionina    | 4 E    | Glu    | Ácido glutámico |

Tabla 1.1: Nombre y código de 1 y 3 letras de los 20 aminoácidos

Figura 1.3: Codones que codifican los aminoácidos

0 X - Xaa desconocido u otro  
2 aminoácido  
1 Z - Glx Glutamina o ácido  
2 glutámico  
2 U

2 B - Asx Ácido aspártico o  
3 Asparagina  
2 O  
4 J  
2

# Sars-CoV-2 (Betacoronavirus Pandemicum)

